

# Pattern Recognition Exercise 3

张素威, MF1733082

May 2018

## 1 讲义6习题3

### 1.a

$$\sigma_1/\sigma_n$$

### 1.b

对矩阵  $A = \begin{bmatrix} 1 & 1 \\ 1 & 1.0001 \end{bmatrix}$ , 用octave计算出的条件数为  $4.0002e + 04$ , 这个值很大, 计算  $Ax = [2, 2]^T$ , 解得  $x = [2, 0]^T$ , 计算  $Ax = [2, 2.0001]^T$ , 解得  $x = [1, 1]^T$ , 可见对  $Ax = b$  来说,  $b$  的 0.0001 的变化对  $x$  的影响很大, 这里的  $A$  就是 ill-conditioned.

### 1.c

对正交矩阵  $A$  来说,  $AA^T = A^T A = E$ , 其奇异值都为 1, 故条件数也为 1. 所以正交矩阵是 well-conditioned.

## 2 讲义6习题6

### 2.c

```
[140: ./opencv/facerec_eigenfaces facerec.csv opencv/eigenfaces/
Predicted class = 39 / Actual class = 39.
Eigenvalue #0 = 2821437.63319
Eigenvalue #1 = 2061768.68526
Eigenvalue #2 = 1097036.82426
Eigenvalue #3 = 892072.93331
Eigenvalue #4 = 819432.79582
Eigenvalue #5 = 539015.30950
Eigenvalue #6 = 390872.85487
Eigenvalue #7 = 373689.19757
Eigenvalue #8 = 313679.14058
Eigenvalue #9 = 289046.71201]
```

Figure 1: PCA运行截图

```
[141: ./opencv/facerec_fisherfaces facerec.csv opencv/fisherfaces/
Predicted class = 39 / Actual class = 39.
Eigenvalue #0 = 67239.08797
Eigenvalue #1 = 4713.30259
Eigenvalue #2 = 1832.97376
Eigenvalue #3 = 1497.24676
Eigenvalue #4 = 631.96906
Eigenvalue #5 = 377.93553
Eigenvalue #6 = 256.68486
Eigenvalue #7 = 197.19217
Eigenvalue #8 = 148.88811
Eigenvalue #9 = 115.20196
Eigenvalue #10 = 85.59302
Eigenvalue #11 = 79.08640
Eigenvalue #12 = 56.77618
Eigenvalue #13 = 46.21607
Eigenvalue #14 = 40.12289
Eigenvalue #15 = 33.86131
```

Figure 2: FLD运行截图

从图中结果可以看出，两者都将最后一张图的类别分类正确，但是PCA得到的eigenvalue远大于FLD得到的特征值，这反应出了PCA和FLD的主要区别，PCA是无监督学习，只会选择大的特征值，FLD则是同时考虑了类间距离和类内距离，在最大化类间距离的同时最小化类内距离，这就使得特征值大小上有所妥协。

## 2.d



Figure 3: Original  
Figure 4: 10 Figure 5: 40 Figure 6: 70 Figure 7: 100 Figure 8: 130



Figure 9: 160 Figure 10: 190 Figure 11: 220 Figure 12: 250 Figure 13: 280

从图中可以看出，使用220个特征值时，人脸已经很清晰了，使用250个特征值时很难看出和原图的差别。

## 3 讲义7习题1

### 3.b

- (i) 66.925%
- (ii) 96.15%(使用[-1,1]scale)
- (iii) 95.675%(scale后的数据)
- (iv) 96.725%(scale后的数据)

(v) 96.95%

对数据集进行合理的scale在svm中起着重要作用，往往能使得结果有飞跃性的进展，数据缩放后的调参只能在局部寻找一个最优的解。

### 3.c

数据集是svmguid3，未使用-wi参数时结果为85.3659%，使用参数-w 1 -w1 3时结果为100%，所以说设置-wi是有用的。

## 4 讲义8习题2

### 4.a

根据概率密度函数积分为1的公式得：

$$\int_{x_m}^{+\infty} \frac{c_1}{x^{\alpha+1}} dx = 1$$

解得  $c_1 = \alpha x_m^\alpha$ 。

所以说  $X$  服从  $\text{Pareto}(x_m, \alpha)$  分布。

### 4.b

将  $x_i$  代入，似然函数为

$$\frac{\alpha^n x_m^{n\alpha}}{(\prod_{i=1}^n x_i)^{\alpha+1}} \mathbb{I}[\min\{x_i\} \geq x_m]$$

指示函数左边的式子关于  $x_m$  单调增。所以  $x_m$  的极大似然估计就是

$$\min\{x_i, 1 \leq i \leq n\}$$

对似然函数左半部取对数求导使为0：

$$\frac{n}{\alpha} + n \ln x_m - \sum_{i=1}^n \ln x_i = 0$$

则  $\alpha$  的极大似然估计为  $\frac{1}{\frac{\sum_{i=1}^n \ln x_i}{n} - \ln x_m}$ 。

### 4.c

由贝叶斯估计公式

$$p(\theta|D) = \frac{(\prod_{i=1}^n p(x_i|\theta))p(\theta)}{\int_{\theta} (\prod_{i=1}^n p(x_i|\theta))p(\theta)d\theta}$$

其中  $p(\theta) = \text{Pareto}(x_m, k)$ ，代入求得：

$$p(\theta|D) = \frac{(k+n)x_m^{k+n}}{\theta^{k+n+1}}$$

证毕！后验分布服从  $\text{Pareto}(x_m, k+n)$ 。

## 5 讲义9习题6

### 5.b

84.17%

### 5.c

87.96%

### 5.d

简单猜想是因为开方运算是非线性运算，对特征开方相当于用了一个简单的核函数进行空间变换，使得结果精读更高。

## 6 讲义10习题2

### 6.a

对于任意 $x, y, z, d$ 需要满足：

非负性： $d(x, y) \geq 0$

自反性： $d(x, y) = 0$  当且仅当  $x = y$

对称性： $d(x, y) = d(y, x)$

三角不等式： $d(x, z) \leq d(x, y) + d(y, z)$

### 6.b

KL散度不满足距离指标的定义要求。KL散度的定义公式为：

$$D(P||Q) = \sum_{x \in X} P(x) \log \frac{P(x)}{Q(x)}$$

计算A, B, C中任意两种分布之间的KL散度：

$$D(A||B) = \frac{1}{2} \log 6 > 0, \quad D(B||A) = \frac{3}{4} \log 3 + \log 2 > 0$$

$$D(A||C) = 2 \log 2 - \frac{1}{2} \log 7 > 0, \quad D(C||A) = \frac{7}{8} \log 7 - 4 \log 2 > 0$$

$$D(B||C) = \frac{1}{4} \log 2 + \frac{3}{4} \log \frac{6}{7} < 0, \quad D(C||B) = -\frac{1}{8} \log 2 + \frac{7}{8} \log \frac{7}{6} > 0$$

显然，KL散度不满足非负性和对称性。

又因为 $D(B||A) > D(B||C) + D(C||A)$ ，所以KL散度不满足三角不等式。

不过KL散度满足自反性。

## 6.c

```
import numpy as np
A = np.array([])
B = np.array([])
C = np.array([])
total = [A, B, C]
M = np.zeros(shape = (len(total), len(total)))
for i in range(len(total)):
    for j in range(len(total)):
        P = total[i]
        Q = total[j]
        M[i, j] = np.sum(P*np.log(P/Q))
print(M)
```

## 7 讲义10习题6

根据题目描述，可以建模出一个求最大熵的优化问题：

$$\begin{aligned} \max_q \quad & \int_{-\infty}^{+\infty} -q(x) \ln q(x) dx \\ \text{s.t.} \quad & \int_{-\infty}^{+\infty} xq(x) dx = \mu > 0 \\ & \int_{-\infty}^{+\infty} q(x) dx = 1 \end{aligned}$$

采用拉格朗日乘子法求解，该优化问题的对偶问题写作：

$$J(q) = \int_{-\infty}^{+\infty} q(x) \ln q(x) dx - \alpha_0 \left( \int_{-\infty}^{+\infty} q(x) dx - 1 \right) - \alpha_1 \int_{-\infty}^{+\infty} xq(x) dx$$

求偏导数：

$$\frac{\delta J}{\delta q}(q) = \ln(q) + 1 - \alpha_0 - \alpha_1 x = 0$$

求得：

$$q(x) = e^{\alpha_0 - 1} e^{\alpha_1 x}$$

将 $q(x)$ 代入第二个约束方程可得：

$$e^{\alpha_0 + 1} = -\alpha_1$$

$q(x)$ 可以写作：

$$q(x) = \lambda e^{-\lambda x}$$

根据随机变量的期望约束可以求得：

$$\lambda = \frac{1}{\mu}$$

即当连续型随机变量服从参数为 $\frac{1}{\mu}$ 的指数分布时，其熵才能达到最大值。